

پروژه درس سیستم‌های هوشمند

سامانه پرسش و پاسخ مبتنی بر RAG + TTS

1) هدف پروژه

هدف این پروژه ساخت یک سامانه «پرسش و پاسخ مبتنی بر یک سند» است که بتواند فقط با تکیه بر محتوای سند پاسخ بدهد. سامانه باید شامل سه بخش اصلی باشد:

(۱) RAG برای پاسخ‌گویی مبتنی بر متن

(۲) رابط چت برای پرسش و پاسخ

(۳) تبدیل پاسخ متنی به صوت (Text-to-Speech)

2) RAG چیست؟

RAG مخفف Retrieval-Augmented Generation است. در RAG، قبل از پاسخ‌دهی، بخش‌های مرتبط از سند بازیابی (Retrieval) می‌شود و سپس مدل زبانی با استفاده از همان بخش‌ها پاسخ تولید (Generation) می‌کند. این کار باعث می‌شود پاسخ‌ها مستندتر و کم‌هذیان‌تر باشند.

3) عملیات‌های RAG Pipeline در این پروژه

- دریافت سند: (Document Ingestion) دریافت متن به صورت paste یا فایل txt
- تکه‌بندی: (Chunking) تقسیم سند به بخش‌های کوچک‌تر با overlap
- بردارسازی: (Embedding) تبدیل هر chunk به یک بردار معنایی
- ایندکس‌سازی: (Indexing) ساخت ایندکس برداری با FAISS
- بردارسازی پرسش: (Query Embedding) تبدیل سوال کاربر به بردار
- بازیابی: (Retrieval) یافتن top-k بخش‌های مرتبط با سوال
- ساخت پرامپت: (Prompt Assembly) اضافه کردن context بازیابی‌شده به پرامپت
- تولید پاسخ: (Generation) تولید پاسخ توسط LLM فقط بر اساس context
- تبدیل متن به صوت: (TTS) تولید فایل صوتی از پاسخ

- رابط کاربری (UI) ارائه یک رابط چت ساده برای تست

(4) خروجی مورد انتظار

- نوت‌بوک Colab/Jupyter قابل اجرا: دانشجو باید نوت‌بوک را طوری آماده کند که در زمان ارائه، از ابتدا تا انتها بدون خطا اجرا شود (از نصب کتابخانه‌ها تا اجرای UI و پاسخ‌دهی).
- در جلسه ارائه، دانشجو باید سامانه را اجرا کند و حداقل ۵ سوال را به‌صورت از متن بپرسد و پاسخ‌های مناسبی را نمایش دهد.
- در ارائه باید پاسخ را به‌صورت زنده به صوت تبدیل کند و پخش کند.
- در ابتدای نوت‌بوک یک بخش کوتاه توضیحی قرار دهید شامل: نحوه اجرا + تنظیمات مهم (chunk_size, overlap, top_k) + مدل‌های استفاده‌شده.

(5) نکات مهم

- پروژه نباید به API پولی وابسته باشد. استفاده از مدل‌های رایگان/متن‌باز مجاز است.
- ارزیابی با پرسش از یک سند بین ۵-۹ هزار کلمه‌ای انگلیسی انجام می‌شود.
- پاسخ باید فقط با استناد به سند باشد. اگر پاسخ در سند نیست، باید صریح اعلام شود.
- بهتر است همراه پاسخ نشان دهید کدام بخش‌های سند بازبازی‌شده (chunks) به عنوان منبع استفاده شده‌اند.
- برای حفظ سرعت و جلوگیری از مصرف زیاد حافظه، مقدار top_k را در بازه‌ی ۳ تا ۵ و max_new_tokens را در بازه‌ی ۱۲۰ تا ۲۰۰ تنظیم کنید.

(6) مدل‌ها و ابزارهای پیشنهادی (رایگان)

- LLM برای پاسخ‌گویی — Qwen2.5-1.5B-Instruct (Generation): [لینک](#)
- مدل Embedding: all-MiniLM-L6-v2 — [لینک](#)
- کتابخانه جست‌وجوی برداری — FAISS: [لینک](#)
- رابط کاربری — Gradio: [لینک](#)
- تبدیل متن به گفتار — gTTS: [لینک](#)

7) مراحل پیاده‌سازی

1. Document Ingestion: متن سند را به صورت Paste یا فایل txt وارد کنید.
2. Chunking: متن را به بخش‌های کوچک‌تر تقسیم کنید (مثلاً $\text{chunk_size}=650$ و $\text{overlap}=120$).
3. Embedding: برای هر chunk یک embedding بسازید.
4. Indexing: سپس embedding ها را داخل یک ایندکس برداری با FAISS ذخیره کنید.
5. Query Embedding: برای هر سؤال کاربر، embedding سوال را بسازید.
6. Retrieval: با استفاده از top_k chunk FAISS، مرتبط را بازیابی کنید (مثلاً $\text{top_k}=5-3$).
7. Prompt Assembly: قسمت های بازیابی شده را به عنوان context همراه با قوانین (»Answer only from context«) به پرامپت اضافه کنید.
8. Generation: با استفاده از مدل زبانی (LLM) پاسخ را تولید کنید.
9. UI + TTS: پاسخ را در رابط چت نمایش دهید و فایل صوتی تولید کنید (Text-to-Speech).

8) بخش امتیازی/اختیاری (Bonus): ترجمه سند فارسی و پاسخ‌دهی با مدل انگلیسی

سامانه RAG باید تشخیص بدهد که متن ورودی فارسی است و در این حالت ابتدا محتوای سند را به انگلیسی ترجمه کرده و بر اساس نسخه انگلیسی عملیات ایندکس‌سازی و بازیابی را انجام دهد؛ سپس در زمان پرسش، سؤال کاربر را (در صورت فارسی بودن) به انگلیسی تبدیل کرده و با استفاده از مدل انگلیسی پاسخ تولید کند، و در پایان پاسخ را دوباره به فارسی ترجمه و نمایش دهد، به طوری که پاسخ همچنان مستند به محتوای سند باشد.

- تشخیص فارسی بودن سند
- ترجمه سند به انگلیسی
- Chunking روی سند انگلیسی
- ساخت embedding و FAISS index روی Chunkها
- در زمان پرسش اگر کاربر فارسی پرسید، سوال را به انگلیسی ترجمه کنید.
- Retrieval و Generation را در انگلیسی انجام دهید. (با همان مدل Qwen)
- پاسخ انگلیسی را به فارسی ترجمه کنید و به کاربر نمایش دهید. (نیازی به تبدیل متن به گفتار نیست).
- برای ارزیابی این قسمت از یک سند فارسی استفاده میشود.

9) راهنمای اجرای پروژه در Google Colab

مدل‌ها و ابزارهای این پروژه طوری انتخاب شده‌اند که روی سیستم‌های معمولی با CPU هم قابل اجرا باشند؛ با این حال اجرای مدل‌های زبانی روی CPU ممکن است کند باشد. به همین دلیل برای اجرای راحت‌تر، سریع‌تر و یکسان بودن شرایط برای همه دانشجویان، پیشنهاد می‌شود پروژه روی Google Colab اجرا شود و در صورت امکان GPU فعال گردد.

- وارد سایت **Google Colab** شوید:
<https://colab.research.google.com>
- از منوی **File → Upload notebook**، نوت‌بوک پروژه با فرمت **ipynb** را آپلود کنید.
- برای فعال کردن GPU، از منوی **Runtime → Change runtime type** وارد تنظیمات شوید.
- گزینه‌ی **Hardware accelerator** را روی **GPU** قرار دهید.
- در پایان روی **Save** کلیک کنید.

10) نحوه تحویل

نوت بوک نهایی را به صورت `RAG_FirstnameLastname.ipynb` در یک فایل zip در کوئرا آپلود کنید.